

Plan de capacidad, hosting y RAG — MAGEAM

Estado: planificación 2026-04-30 · Autor: David Cabezas
Disparador: 93 usuarios totales potenciales (incidente Hostinger reveló cuello de botella) + funciones agénticas Phase 2 que requieren RAG.
Decisión tentativa: migrar a **Vultr Santiago** + agregar Redis + preparar infra RAG.

1. Diagnóstico de capacidad actual

Setup hoy

- VPS:** Hostinger KVM 2 — 2 vCPU, 4 GB RAM, 100 GB disco. CPU en uso 7%, RAM 32%, disco 52 GB usados.
- DB:** SQLite (1 archivo, 1 escritor concurrente).
- Backend:** FastAPI + uvicorn 1 worker (limitación intencional por WebSocket state in-process — ver Dockerfile línea ~50).
- Frontend:** Vite served via nginx.
- Cache:** ninguno (queries pegan DB cada vez).
- WebSocket:** state en memoria del único worker (`api/services/ws_manager.py`).
- LLM:** Anthropic API (Claude Sonnet 4.6), sin retry, sin queue.
- Costo actual:** ~\$15/mes Hostinger + ~\$15/mes Anthropic (con uso real de Goldfields).

Aguante real (estimado, no medido)

Carga concurrente	Setup actual	Riesgo
5–10 users	✅ funciona bien	Bajo
15–20 users	⚠️ degrada en endpoints pesados (PA, Pareto, page-data)	Medio
30+ users	❌ SQLite locks, WS lag, OOM probable	Alto

Cuellos de botella en orden

1. **Queries pesadas sin cache** (Performance Analysis, Pareto, page-data, gantt): cada user que abre PA dispara 6-10 queries SQLite + 4 llamadas Claude. Con 10 users concurrentes → 60+ queries simultáneas + 40 llamadas Claude paralelas.
2. **SQLite write lock**: notificaciones parciales, updates de OT, drag-drop en scheduling. Con 5+ writers simultáneos hay lock contention real.
3. **Anthropic rate limit**: ~50 req/min en tier estándar. 100 users abriendo `/agentic-capabilities` o `/performance-analysis` simultáneamente lo satura.
4. **WS in-process**: 1 worker = todos los WS por el mismo proceso. Subir a 4 workers ahora rompe WS broadcast.

2. Target: 100 usuarios totales (~15-20 concurrentes pico)

Regla industrial: ~15-20% concurrent active de la base total. Con 100 totales esperamos pico 15-20.

Plan de cambios por ROI (orden de impacto/costo)

#	Cambio	Tiempo	Costo	Beneficio
1	Redis cache para queries pesadas (TTL 60-120s)	4-6 hrs	\$0 (Redis local)	-70% load DB en endpoints más pegados
2	VPS upgrade a 4 vCPU / 8 GB	5 min + reboot	+\$15-20/mes	x2 RAM, headroom para Redis + RAG
3	Migración Hostinger → Vultr Santiago	4-6 hrs	similar	uptime y latencia mucho mejor
4	Migrar ws_manager → Redis pub/sub	1-2 días	\$0	Habilita gunicorn -w 4 sin perder WS
5	gunicorn -w 4 (después de #4)	30 min	\$0	x4 throughput real
6	PostgreSQL + pgvector (sólo si SQLite truena con monitoring)	2-3 días	\$0 (mismo VPS)	Escrituras paralelas + base para RAG nativa

Recomendación para arrancar (orden de ataque):

- **Fase 1 (esta semana)**: #1 + #2 + #3 → soporta 25-30 concurrentes cómodo, mejor uptime.
- **Fase 2 (cuando llegue a 25 reales)**: #4 + #5.
- **Fase 3 (cuando SQLite muestre locks en logs)**: #6.

3. Decisión de hosting: Vultr Santiago

Por qué se descarta Hostinger

- **Incidente 2026-04-30:** VPS unreachable durante demo, panel decía "Funcionando" mintiendo.
- Soporte lento, sin SLA.
- Sin servidores en Chile/LATAM (datacenter en EU/US → +200ms latencia).

Vultr — tiers disponibles para Santiago (Regular Performance)

Verificado en panel Vultr 2026-04-30:

Plan	vCPUs	RAM	Storage	BW	\$/mes	\$/hr
Pequeño	2 vCPU	4 GB	80 GB	3 TB	\$20	\$0.03
Recomendado 	4 vCPU	8 GB	160 GB	4 TB	\$40	\$0.06
Holgado	6 vCPU	16 GB	320 GB	5 TB	\$80	\$0.11

Decisión revisada: arrancar con **2 vCPU / 4 GB / \$20/mes** (igual que la KVM 2 actual de Hostinger pero en Santiago + más confiable). Subir a \$40 sólo si las métricas del primer mes lo piden.

Por qué arrancar chico:

- Hoy CPU 7% y RAM 32% con uso liviano — el plan \$20 igual da margen para cache Redis y RAG inicial.
- LanceDB + MiniLM agregan ~500-700 MB RAM → quedaríamos en ~70% RAM con \$20 plan, ajustado pero no crítico.
- Si llega 25-30 concurrentes reales, upgrade en caliente a \$40 sin downtime (Vultr permite resize).

Comparativa de hosting (todos en plan equivalente 4 vCPU/8 GB)

Provider	Datacenter más cercano a Chile	Precio	Pros	Contras
Vultr  elegido	Santiago de Chile	\$40/mes	Latencia mínima Chile, snapshots, soporte 24/7	—
Hetzner	Helsinki / Falkenstein	\$15/mes	Más barato, infra sólida	+200ms latencia LATAM
DigitalOcean	São Paulo	~\$48/mes	Docs excelentes	Más caro
Linode (Akamai)	Miami	\$36/mes	Buena red	Lejos de Chile
AWS Lightsail	Virginia / São Paulo	\$40/mes	Confiable	Complejo, lock-in

Plan de migración Hostinger → Vultr

1. Crear instancia Vultr Cloud Compute en Santiago (4 vCPU, 8 GB, 80 GB SSD NVMe).
2. Apuntar `mageam.com` → IP Vultr en Cloudflare (low TTL días antes).
3. `git clone` repo en Vultr, `docker compose up -d`.
4. Migrar `ocp_db_data` volume (snapshot Hostinger → tar → scp → restore en Vultr).
5. Cutover DNS → confirmar funciona → bajar Hostinger.
6. Mantener Hostinger 30 días como backup pasivo, después dar de baja.

Ventana de downtime esperada: 30-60 min en cutover (en horario nocturno fin de semana).

4. Infra RAG (Phase 2 — funciones agénticas pendientes)

Las 4 cards de Capa 6 que requieren RAG (`docs/AGENTIC_SOLUTIONS_ROADMAP.md` + `Ayudas/GUIA_RAG.md`):

#	Capacidad	Tipo de RAG	Stack mínimo
#34	Shift Handover Assistant	Vectorial sobre OTs cerradas + execution_notes del turno	LanceDB + MiniLM
#35	Post-Maintenance Learning	Vectorial sobre cierres + RCAs (causas → soluciones efectivas)	LanceDB + MiniLM
#40	Knowledge Base Curator	Vectorial sobre manuales OEM + cierres + RCAs + FMECA worksheets	pgvector si migra Postgres
#33	RCM Strategy Advisor	Híbrido: estadística Weibull + retrieval de OTs similares + Claude analiza	LanceDB + Weibull existente

Decisión vector DB

Opción A — LanceDB (recomendada para arrancar)

- 1 archivo en disco, sin servicio extra.
- Embeddings con `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` (local, CPU, 384-dim).
- Costo \$0, RAM extra ~500 MB para el modelo.
- Apto hasta ~1M chunks.

Opción B — pgvector (si ya migramos a Postgres)

- Tabla `embeddings` con extensión vectorial.
- Mismo Postgres que app data → 1 menos servicio.
- Permite joins SQL: "OTs cerradas similares a esta + costos".
- Recomendado a partir del segundo cliente o si reaching 1M chunks.

Opción C — Qdrant cloud (si crecemos a multi-tenant)

- Servicio dedicado, gestión cero.
- ~\$25/mes hosted.
- Sólo justifica si ya >5 clientes.

Decisión actual: empezar con **LanceDB local + MiniLM** (Opción A). Migrar a pgvector cuando tengamos Postgres.

Costos LLM con RAG

- Embedding cada chunk una vez (MiniLM local = \$0).
- Por query RAG: 1 embedding (gratis) + 1 llamada Claude con contexto retrieved.
- Contexto típico: 5 chunks × 500 tokens = ~2500 tokens input + ~300 output = ~\$0.012/query.
- Estimado con 100 users y uso moderado de RAG (10 queries/user/día): 1000 queries/día × \$0.012 = ~\$12/día = **~\$360/mes** Anthropic adicional para Phase 2.

Capacidad RAM con RAG

Componente	RAM aprox
Backend FastAPI	200 MB
Frontend (nginx)	50 MB
Redis	100-200 MB
LanceDB index (~50K chunks)	300 MB
MiniLM model loaded	500 MB
Embeddings cache	200 MB
Total backend RAG-ready	~1.5 GB

Con 8 GB del Vultr → margen amplio para 100 users.

5. Métricas a monitorear cuando llegue a producción

Agregar antes del go-live con 93 users:

1. **Sentry** (frontend + backend) → ya está configurado pero verificar que llegue al dashboard.
2. **VPS metrics** (Vultr panel + node_exporter): CPU, RAM, disk I/O, network.
3. **DB locks SQLite**: log warning si `OperationalError: database is locked` aparece >0.
4. **Anthropic spend**: dashboard Anthropic + alerta si pasa \$X/día.
5. **Latencia endpoints**: middleware que loguea p95/p99 de cada endpoint, alerta si p99 > 5s.
6. **WS connection count**: gauge en `/health` con número de conexiones activas.

Umbrales de alerta:

- CPU sostenido > 70% durante 10 min → ampliar vCPU.
- RAM > 80% sostenido → ampliar RAM o investigar leak.
- DB locks > 5/min → migrar a Postgres ya.
- Latencia p99 > 8s en `/analytics/page-data` → cache TTL más largo o queries optimizadas.
- Anthropic spend > \$30/día → cache RAG más agresivo o modelo más barato (Haiku para clasificaciones simples).

6. Costo total mensual estimado al estado final (Vultr + RAG en producción con 100 users)

Escenario A — arrancar chico (recomendado):

Concepto	Costo mensual
VPS Vultr Santiago (2 vCPU, 4 GB, 80 GB)	\$20
Anthropic API (uso actual sin Phase 2 RAG)	~\$30
Backups (Vultr snapshot semanal)	\$5
Dominio + Cloudflare Free	\$0
TOTAL inicio	~\$55/mes

Escenario B — al activar Phase 2 RAG + más users:

Concepto	Costo mensual
VPS Vultr Santiago (4 vCPU, 8 GB, 160 GB)	\$40
Anthropic API (PA actual + RAG Phase 2)	~\$60
Backups	\$5
TOTAL Phase 2	~\$105/mes

Escenario C — si crecemos a 200+ users: 6 vCPU / 16 GB Vultr = \$80/mes → total <\$150/mes. Manejable comercialmente (cobrarle al cliente \$300-500/mes deja margen sano).

7. Próximos pasos concretos

- [] **Esta semana:** Redis cache (Fase 1 #1), upgrade VPS Hostinger (Fase 1 #2) o ya migrar a Vultr (Fase 1 #3).

- [] **Próxima semana:** instrumentar métricas (Sentry, latency middleware, db lock counter).
 - [] **Antes de invitar 93 users:** load test sintético (locust o k6) simulando 30 concurrent → validar que no cae.
 - [] **Phase 2 RAG (después de soak Phase 1):** implementar LanceDB + MiniLM + endpoints #34/#35/#40.
 - [] **Cuando aparezca primer DB lock real:** migrar a Postgres + pgvector.
-

8. Decisiones tomadas hoy

- ☒ Hosting: **Vultr Santiago** (\$24/mes).
 - ☒ DB inicial: SQLite + Redis cache (no migrar Postgres todavía).
 - ☒ Vector DB inicial: **LanceDB local** + MiniLM multilingüe.
 - ☒ WebSocket: mantener -w 1 hasta migrar a Redis pub/sub.
 - ☒ Workers: 1 hasta tener pub/sub, después 4.
 - ⚠ Pendiente: timing de migración Hostinger → Vultr (depende de cuándo confirmamos los 93 users).
-

Documento vivo · actualizar tras cada decisión de infra.