

Inventario técnico de funciones IA

Qué endpoints invocan a Claude · prompts · status real · costos

Autor: David Cabezas

Fecha: 2026-04-30

Audiencia: Gonzalo (Producto)

Modelo: claude-sonnet-4-6

Resumen ejecutivo. MAGEAM tiene **9 endpoints que invocan Claude (Sonnet 4.6)** y **13 capacidades algorítmicas** sin LLM. Las 22 cards de */agent-capabilities* ya no exageran — cada una declara honestamente si usa IA o algoritmo. Costo estimado: **~\$15/mes per planta** (Goldfields) con ~50 llamadas/día. Todas las funciones IA tienen fallback determinístico si Anthropic responde mal o si la API key no está seteada.



Distribución por capa del flujo

Capa	Funciones IA reales	Algoritmos sin LLM	Total
1 · Captura	#1 Vision · #2 Voice · #4 Classification	#3 Duplicate detect	4
2 · Validación + Plan	#6 Smart Assignment · #7 Auto-Level NL	#5, #8, #9 (reglas SAP)	5
3 · Ejecución	—	#10, #11, #12	3
4 · Análisis	#14 Crónicas · #18 NLP · #19 OC · #20 Cost	#13, #15, #16, #17	8
5 · Cierre	—	#21, #22	2
TOTAL	9 endpoints Claude	13 algoritmos	22

Endpoints con Claude (LLM real)

Cada endpoint listado abajo invoca **claude-sonnet-4-6** vía Anthropic SDK. Si la API key no está seteada o Claude responde mal, el fallback determinístico (heurística keyword o default) se activa transparentemente.

#1

Vision AI · foto → equipo + falla

FUNCIONAL

Endpoint: POST /api/v1/captures/photo

Servicio: api/services/vision_service.py

Input: imagen base64 · **Output:** {equipment_tag_detected, failure_mode_detected, confidence}

Trigger UI: /failure-capture · botón cámara

#2

Voice capture · dictado → WR estructurado

FUNCIONAL

Endpoint: POST /api/v1/agentive/voice-capture

Servicio: agentive_voice_capture_service.py · _classify_with_claude

Output: {failure_category, failure_object_part, failure_symptom, failure_cause, suggested_action, priority, priority_reason, work_conditions}

Prompt: catálogo SAP cerrado (MEC/ELEC/INST × partes/síntomas/causas) — Claude elige UN valor exacto de cada lista

#4

AI Classification del form manual

FUNCIONAL

Endpoint: POST /api/v1/work-requests/manual

Cuándo: al submit con problem_description no vacío

Bump prioridad: si Claude detecta más severidad que la del usuario (ej: 'humo + emergencia') levanta a P1/P2 con flag priority_bumped_by_ai + ai_priority_reason

Status: antes era stub. Real desde 2026-04-30.

#6

Smart Assignment con razonamiento

FUNCIONAL

Endpoint: POST /api/v1/assignments/rank-for-operation

Pipeline: scoring algorítmico (40 specialty + 30 skill + 20 shift + HH) ranquea top-10 → Claude analiza top-3 → recommended_worker_id + reasoning + warnings

Caso real: 3 técnicos con score 68 idéntico — Claude desempata por skill 'soldadura' contra descripción del WO

#7	Auto-Level NL parser	FUNCIONAL
Endpoint: POST /api/v1/scheduling/parse-autolevel-instructions Input: texto NL ('lunes liviano por reunión, prioriza chancador') + WOs + días semana Output: {priority_boost_wos, priority_boost_equipment, deprioritize_wos, light_days, excluded_days, capacity_override_pct, include_weekend, summary} Mejora sobre keywords: mapea 'lunes' a fecha real (2026-04-28), entiende equipos por tag		
#14	Crónicas con causa raíz	FUNCIONAL
Endpoint: POST /api/v1/analytics/chronic-failures-analyze Input: clusters detectados algorítmicamente (≥3 reps en 7d) + sample descriptions Output: {root_cause_hypothesis, recommended_action, confidence: high medium low} Ejemplo: 'PMP-AGUA-01 vibración axial 4x' → 'rodamiento NDE deteriorado, reemplazar + verificar juego axial'		
#18	NLP causas no-cumplimiento	FUNCIONAL
Endpoint: POST /api/v1/analytics/classify-noncompliance Clasifica en 7 categorías Jorge: REPUESTO_FALTANTE, OPERACIONES_NO_LIBERO, SERVICIO_EXTERNO_NO_LLEGO, HERRAMIENTA_FALTANTE, EQUIPO_APOYO_NO_DISPONIBLE, VENTANA_INSUFICIENTE, SEGURIDAD_LOTO Detecta emergentes: 'no había soldador certificado' → categoría nueva PERSONAL_INSUFICIENTE Antes era: 7 regex hardcodedos		
#19	Stock OC recommend con justificación	FUNCIONAL
Endpoint: POST /api/v1/analytics/stock-oc-recommend Input: forecast determinístico (consumo 90d + demanda 60d + stock disp) Output: {qty_suggested, priority: HIGH MEDIUM LOW, reasoning citando los números clave} Ejemplo: 'Cobertura 2.5d (<7d); demanda 60d=10. Sugiero OC 8 uds para cubrir 60d descontando stock actual (2)'		
#20	Cost element classifier	FUNCIONAL
Servicio: cost_analysis_service.py · _classify_materials_with_claude Cuándo: al computar cost_analysis si un material tiene description pero falta cost_element 7 categorías SAP: REPUESTO_CONSUMIBLE/CRITICO/ELECTRICO, INSUMO_LUBRICANTE, HERRAMIENTA_EQUIPO, MANO_DE_OBRA, SERVICIO_EXTERNO Cache: _COST_ELEMENT_CACHE en memoria global (no re-clasifica descripciones repetidas)		

Capacidades sin LLM (algoritmo)

Estas 13 cards **funcionan sin invocar Claude** porque la lógica es determinística: reglas SAP, fórmulas matemáticas, correlaciones temporales. **El label de cada card refleja honestamente** que no usa IA — no se exagera. Beneficio: lógica auditable, sin riesgo de alucinación, costo cero.

#	Capacidad	Lógica
#3	Duplicate detection	jaccard + sequence ratio + time-decay 7d + severity filter ± 2
#5	Express PM03 (1 click)	regla SAP fast-track: WR P1/P2 $\rightarrow$ OT directo en PROGRAMADO
#8	Bloqueo PM01/02 $\rightarrow$ falla	HTTPException 409 si intentás cambiar PM01 con priority P1/P2
#9	Cancelación con tipología	dropdown ABSORBED/NOT_NEEDED/OTHER + linkeo absorbed_by_wo_id
#10	Notif parcial multi-turno	agrupa por shift + technician + WS broadcast cuando todas las ops 100%
#11	Pre-close gates (5)	ALL_OPS_DONE $\cdot$ HH_VARIANCE_OK $\cdot$ MATERIALS_OK $\cdot$ SUPERVISOR_QA $\cdot$ NO_OPEN_NOTIFS
#12	Stock auto-decrement	hook idempotente al CERRAR — descuenta materials del inventory
#13	Bad Actors $\times$ Críticos	cruce con criticality A/B threshold ≥ 2 fallas, C/D ≥ 3
#15	Auto-RCA trigger	scan closed P1/P2 + 5W2H pre-fill template
#16	Retrabajos <24h	correlación temporal: equipo cerrado + nuevo WR en <24h del mismo equipo
#17	Pareto + Jack-Knife	fórmulas Jorge validadas 1:1 contra Excels históricos Sept/Oct/Dic 2010
#21	FMECA push auto	al cerrar RCA registra/actualiza FMECA worksheet con RPN before/after
#22	Close-the-loop tracking	cuenta improvement_actions abiertas/vencidas/cerradas + warnings

Modelo de decisión: ¿Claude o algoritmo?

Criterio	Usar Claude	Usar algoritmo
Texto libre del usuario	■ Sí — NLP es necesario	—
Catálogo cerrado (P1/P2, MEC/ELEC)	■ Si hay que mapear desde NL	■ Si ya viene estructurado
Decisión con razonamiento ('por qué este')	■ Output con reasoning explícito	—
Cálculo numérico determinístico (HH, %, suma)	—	■ Siempre
Auditoría regulatoria (no se puede alucinar)	—	■ Siempre
Ranking + interpretación	■ Híbrido: algoritmo rankea, Claude explica	—

Costos estimados (Anthropic Sonnet 4.6)

Pricing referencia: **\$3 USD por 1M tokens input, \$15 USD por 1M tokens output**. Latencia típica 2-7s por llamada (sync, sin streaming).

Función	Tokens in	Tokens out	Costo/llamada
#4 AI Classification	~500	~200	~\$0.005
#6 Smart Assignment	~600	~150	~\$0.004
#7 Auto-Level parser	~800	~250	~\$0.006
#14 Crónicas analyze	~700	~400	~\$0.008
#18 NLP causas (80 notas)	~2000	~600	~\$0.015
#19 OC recommend	~1500	~500	~\$0.012
#20 Cost element batch	~1500	~500	~\$0.012
TOTAL ~50 llamadas/día	—	—	~\$0.5/día = ~\$15/mes

Optimización futura: con cache compartido entre WRs similares (mismo equipo + mismo failure_mode) bajaría a **~\$5-8/mes per planta**. También se puede usar Haiku 4.5 para clasificaciones simples (#4, #20) y reservar Sonnet para tareas con razonamiento (#6, #14) — bajaría otro ~40%.

Phase 2 — funciones IA pendientes

De los 20 items en Capa 6 (/agentic-capabilities), **4 requieren Claude real**. Los demás son determinísticos (conector Jigsaw, KPI Watchdog, dashboards HSE, etc.).

#	Capacidad	Descripción
#33	RCM Strategy Advisor	Analiza histórico Weibull + falla → propone cambio frecuencia preventiva
#34	Shift Handover Assistant	Consolida turno saliente para entrante (OTs, pendientes, alertas)
#35	Post-Maint Learning	Embeddings + retrieval para troubleshooting basado en cierres previos
#40	Knowledge Base Curator	Auto-tag + búsqueda semántica de manuales / RCAs / cierres

Archivos clave del codebase

Componente	Path
Backend · Voice + Classification	api/services/agentic_voice_capture_service.py
Backend · Smart Assignment	api/routers/assignments.py · _claude_recommend_technician
Backend · Auto-Level + NLP causas + Crónicas + OC	api/routers/analytics.py · api/routers/scheduling.py
Backend · Cost classifier	api/services/cost_analysis_service.py · _classify_materials_with_claude
Backend · Manual form classify	api/routers/work_requests.py · /manual
Frontend · Performance Analysis	frontend/src/pages/PerformanceAnalysis.jsx
Frontend · Scheduling + Auto-Level wizard	frontend/src/pages/Scheduling.jsx
Frontend · Smart Assign modal	frontend/src/components/SmartAssignModal.jsx
Docs relacionados	docs/AGENTIC_CAPABILITIES.md · PRESENTACION_FUNCIONES_AGENTICAS.md · AGENTIC_SOLUTIONS_ROADMAP.md

Configuración VPS. ANTHROPIC_API_KEY env var seteado en container ocp-backend. Modelo claude-sonnet-4-6 hardcoded. Sin retry automático — fallback determinístico si Claude falla. Tag git de respaldo del estado actual: **backup-2026-04-30-crew-styled-confirm**.

Documento vivo · actualizo con feedback de Gonzalo · MAGEAM 2026