

Ciberseguridad — Por qué necesitamos revisión humana especializada

Autor: David Cabezas (dev full-stack junior)

Destinatario: José (decisión de hiring / scope security)

Fecha: 2026-04-23

Contexto: Plataforma AMS (Mageam) con integración SAP PM, data industrial crítica (Goldfields).

TL;DR

Hoy corrí un audit defensivo con Claude y **encontramos 5 vulnerabilidades CRÍTICO/ALTO que ya parcheé**. Pero una IA tiene techos duros en seguridad: **no puede atacar, no puede explotar cadenas de bugs, no tiene contexto del atacante real**. Sin un rol de seguridad humano (interno o consultor externo), quedamos expuestos a los mismos tres escenarios que llevan a incidentes en la industria minera.

Qué hizo Claude en el audit de hoy

- **Static analysis de código:** grep de patrones peligrosos (IDOR sin `assert_plant` , inyección HTML sin escape, `hmac` faltante).
- **Detección de endpoints nuevos sin auth:** enumeró los 6 endpoints que agregué hoy y verificó que tuvieran `require_role` o `get_current_user` .
- **Fixes automáticos:** parches IDOR + XSS + timing attack en 4 archivos, commiteados en minutos.
- **OWASP Top 10 checklist:** revisó inyección SQL, XSS, CSRF, mass assignment, path traversal, SSRF, secretos hardcoded.

Vulnerabilidades encontradas y arregladas hoy:

- IDOR crítico en FMECA (usuarios podían leer recursos de otras plantas).
 - IDOR en Cancel WR (supervisor podía cancelar avisos de otra planta).
 - AuthZ faltante en export SAP-IW22 y from-RCA.
 - XSS en ExecutiveView (respuestas AI sin escape antes de parse markdown).
 - Timing attack en comparación de DEPLOY_SECRET.
-

Qué Claude NO puede hacer — 4 huecos que obligan a un rol humano

1. Explotación activa (pentest real)

- **Limitación IA:** No puedo **atacar** la plataforma. Sólo leo código. Un pentester humano corre Burp Suite, fuzzing de parámetros, prueba cadenas de bugs (SQLi + SSRF + lectura de archivos), valida

que los fixes realmente bloqueen la explotación.

- **Ejemplo concreto:** Arreglé el IDOR poniendo `_assert_plant_access`. ¿Pero funciona si alguien pasa `plant_id=null`? ¿Y si lo pasa URL-encoded dos veces? ¿Qué pasa si el JWT no trae `plant_id`? Un pentester prueba **las cinco variaciones** en 10 min. Yo sólo puedo prever las obvias.
- **Qué hace un rol humano:** pentest trimestral, bug bounty interno, red team exercises.

2. Entender al atacante real del contexto minero

- **Limitación IA:** No conozco las amenazas específicas del sector. Una minera puede ser objetivo de:
 - **Ransomware industrial** (Conti, LockBit apuntaron a mineras 2022-2024).
 - **Sabotaje OT/IT** (competidores, grupos activistas ambientales).
 - **Insider threats** (contratistas con acceso temporal que llevan data).
 - **Espionaje industrial** (estrategias de mantenimiento son IP valiosa).
- **Ejemplo concreto:** La integración SAP-IW22 que agregué hoy exporta datos de OTs + equipos + costos en CSV. **¿Qué data sensible sale? ¿Quién puede descargarlo?** Le puse `require_role(admin/manager/planner)` pero no sé si en el contexto de Goldfields un **planner externo contratista** debería poder exportar toda la estrategia de mantenimiento.
- **Qué hace un rol humano:** threat modeling con contexto del cliente, clasificación de data (PII/IP/operacional/pública), diseño de controles por rol real de Goldfields.

3. Operaciones de seguridad en vivo (SecOps)

- **Limitación IA:** Yo reviso código una vez. **No monitoreo logs 24/7**. No detecto cuando alguien está probando credenciales cada 3 segundos, cuando el endpoint de login recibe 10k requests desde una IP sospechosa, cuando un usuario legítimo de repente descarga 50 OTs a las 3am.
- **Ejemplo concreto:** Hoy bajamos el rate-limit a 600/min por un bug de UX. **Eso abrió la puerta a brute-force de login** (auth_limit sube a 20r/m via nginx, pero el app-level permite 600). Un SOC detectaría el pico; Claude no puede.
- **Qué hace un rol humano:** SIEM (Splunk, Datadog), alertas activas, respuesta a incidentes, rotación de secretos, forense post-breach.

4. Compliance y auditoría formal

- **Limitación IA:** No firmo reportes, no certifico. Mineras grandes (Goldfields, Codelco, BHP) exigen:
 - **ISO 27001** certificación del proveedor SaaS.
 - **SOC 2 Type II** (auditoría externa anual).
 - **Chile Ley 21.663** (protección de datos personales, vigente 2024).
 - **Data Processing Agreement** (DPA) con cliente.
 - **Ejemplo concreto:** Goldfields probablemente ya pidió (o pedirá) evidencia de cómo manejamos data. Yo escribí código que guarda firmas de supervisor, fotos de fallas, PINs truncados. **¿Eso pasa una auditoría ISO 27001? No tengo idea — no soy auditor.**
 - **Qué hace un rol humano:** prepara documentación (políticas, procedimientos, DPA), gestiona auditorías externas, coordina con el cliente cuando piden evidencia de controles.
-

Lo que Claude + David logra (y lo que deja expuesto)

Capa	Cubierto hoy	Hueco si no hay seguridad humana
Code review estático	parches IDOR/XSS/timing	Ataques combinados (SQL+SSRF)
Configuración infra (nginx, docker)	headers, CORS, HSTS	Hardening VPS (ssh-keys, fail2ban, updates OS)
Autenticación	bcrypt, JWT 32+ chars, MFA	Gestión de secretos (rotación, vault)
Secretos en repo	.gitignore validado	Secrets scanning CI
Pentest real	NO	Sólo humano
SOC / monitoreo	NO	Sólo humano
Compliance	NO	Sólo humano
Threat modeling cliente-específico	Parcial	Sólo humano

Vectores reales a los que estamos expuestos HOY

- 1. Tabnabbing + phishing SAP:** usuarios con sesión abierta en mageam.com + mismo browser en Outlook corporativo = crafted link puede robar token si no hay SameSite strict + CSRF.
- 2. Supply chain (dependencias npm/pypi):** agregué 2 librerías hoy. Ninguna verificación de si están firmadas, auditadas o comprometidas (caso event-stream 2018, ua-parser-js 2021).
- 3. Insider threat — contratista planner:** hoy un planner puede exportar IW22 de toda la planta. Si se va a la competencia, se lleva la estrategia de mantenimiento en un CSV.
- 4. VPS sin hardening:** deployamos en un VPS root@IP directo. ¿SSH con keys? ¿Fail2ban? ¿Updates automáticos del OS? No lo verifiqué.
- 5. Logs sensibles:** los logs del backend muestran WebSocket path con plant_id + client_id. Si alguien accede a los logs, tiene información de planta + usuarios conectados.

Seguridad = código + documentación (no sólo parchar)

Igual que QA, ciberseguridad real **exige documentación obligatoria**. Especialmente con clientes mineros grandes como Goldfields que piden evidencia formal:

Documento que seguridad escribe	Para qué sirve	Sin rol humano
Política de seguridad de la información	Doc maestro exigido por ISO 27001, contratos B2B.	No existe, no podemos firmar DPA.
Threat model	Matriz activos × amenazas × controles. Actualizada por release.	Volamos a ciegas.
Matriz de roles y permisos	Documentada en detalle: qué puede hacer admin vs manager vs planner vs supervisor vs técnico.	IDOR de hoy vuelve a pasar.
Plan de respuesta a incidentes	Qué hacer si se filtra un token, si hay ransomware, si un contratista roba data.	Improvisamos en plena crisis.
Registro de auditoría	Qué usuario hizo qué cambio, cuándo. Exigido legalmente para data de mantención crítica.	Tenemos log básico pero sin retención formal.

DPA (Data Processing Agreement)	Contrato legal con Goldfields sobre cómo tratamos su data.	Goldfields lo va a pedir y no lo tenemos.
Reporte de pentest	Evidencia que el SaaS fue auditado externamente.	Cliente pide, no tenemos.
Cumplimiento Ley 21.663 Chile	Obligatorio desde 2024 para data personal.	Riesgo legal.
Bitácora de secretos rotados	Cuándo se rotó JWT_SECRET, credenciales DB, API keys.	Si hay filtración, no sabemos qué rotar.
Inventario de dependencias	SBOM (Software Bill of Materials) con hash de cada lib.	Supply chain attack indetectable.

Sin esta documentación:

- Goldfields puede rechazar el go-live por falta de compliance.
- Un incidente futuro no tiene forense (no sabemos qué pasó).
- Legal queda expuesto ante demanda por Ley 21.663.
- Auditoría externa (ISO 27001, SOC 2) imposible.

Propuesta de scope Seguridad

Mínimo viable (externo, una vez):

1. **Pentest tercerizado** — 40h una vez antes del go-live con Goldfields (~\$3-5k USD Chile).
2. **Revisión de compliance** — abogado/consultor Ley 21.663 (~8h consultoría).
3. **Hardening VPS** — SysAdmin 10h (ssh-keys, fail2ban, auto-updates, backups cifrados, cert Let's Encrypt rotativo).

Recurrente (interno part-time, 10h/semana):

1. Monitoreo básico de logs (Grafana Loki + alertas a Slack).
2. Actualización mensual de dependencias (pip-audit, npm audit).
3. Revisión post-deploy de cada feature que toque auth/permissions/data export.
4. Respuesta a incidentes (plan escrito de qué hacer si se filtra un token).

Ideal (si crecen los clientes):

- Certificación ISO 27001 (6-12 meses, ~\$15k USD).
- SOC 2 Type II (anual, ~\$30k USD).
- Bug bounty privado (HackerOne / Intigriti).

Conclusión para José

Hoy arreglé 5 vulnerabilidades reales. Eso valida que el audit sirve. Pero **lo que no vemos es lo que mata**. Una IA cubre el 70% del security review de código; el 30% restante (pentest real, SecOps 24/7, compliance, threat modeling del sector) exige humanos especializados.

Con Goldfields entrando a producción, **el costo de una brecha es muy superior al costo de un consultor de seguridad tercerizado 40h**. Mi recomendación: pentest externo antes del go-live + hardening del VPS + plan básico de respuesta a incidentes. Eso es el piso mínimo defendible ante el cliente.