

SPIKE-1: Evaluación de despliegue

Azure vs Google Cloud (SF-629)

Fecha: 2026-05-05
Stack actual: Hetzner VPS (Ubuntu 24.04) · 96GB SSD · 8GB RAM · Docker Compose · SQLite + LanceDB
Costo actual aprox: ~25 EUR/mes

Contexto

AMS-Production corre hoy en una VPS de Hetzner con 12 proyectos coexistiendo. Para escalar a múltiples plantas (Gold Fields, OCP-Maroc, FluorAlpha) sin riesgo cruzado y con SLA de cliente minero, se evalúa migrar a una nube hyperscaler.

Comparativo

Compute (backend FastAPI + frontend Vite/Nginx)

Atributo		
Equivalente	App Service / Container Apps	Cloud Run
Modelo facturación	vCPU-seg + memoria	vCPU-seg + memoria + requests
Cold start (containerized)	2-5s	0.5-2s
Auto-scale a 0	Sí (Container Apps)	Sí (Cloud Run)
Costo 1 vCPU + 2GB always-on (24x30)	~\$60/mes	~\$50/mes
Concurrent requests por instancia	10-100 (configurable)	80-1000 (configurable)

Persistencia (BD)

Atributo		
Postgres managed	Azure Database for PostgreSQL	Cloud SQL Postgres
Tier mínimo razonable	Burstable B1ms (1 vCPU 2GB) ~\$12/mes	db-f1-micro (0.6GB) ~\$10/mes pero suben rápido
Backups automáticos	Sí, 7 días incluido	Sí, 7 días incluido
Networking	VNet integration	VPC peering / Private IP

Storage (fotos, DMS PDFs, audio capturas)

Atributo		
Object storage	Blob Storage (Hot tier)	Cloud Storage (Standard)
Costo /GB/mes	~\$0.018	~\$0.020
Egress 1TB	~\$87	~\$85
URLs firmadas	SAS tokens	Signed URLs

IA / LLM

Atributo		
Hosted Claude	✗ (Anthropic API directo)	✗ (Anthropic API directo)
Vertex AI / Azure OpenAI	Sí (GPT-4o, Claude via marketplace)	Sí (Gemini 1.5 Pro/Flash)
Vector DB managed	Cosmos DB con vector search	Vertex AI Vector Search / AlloyDB
LanceDB hosted?	No nativo, autohostear en VM	No nativo, autohostear en VM
Latencia desde Chile/Marruecos	Mejor con regiones Brazil South / France Central	Mejor con regiones South America East / Europe West

Networking & Multi-región

Atributo		
Regiones LATAM	Brazil South (São Paulo)	South America East (São Paulo), Santiago (~2026)
Regiones EU	Multiple, France Central activo	Europe West (Bélgica/Holanda)
CDN	Front Door / Azure CDN	Cloud CDN
Certificate management	Auto-renew con App Service	Auto-renew con managed certs

DevOps / CI

Atributo		
Container Registry	ACR	Artifact Registry
CI/CD nativo	Azure DevOps / GitHub Actions integration	Cloud Build + GitHub trigger
Secrets	Key Vault	Secret Manager
Observability	Application Insights (incluido en App Service)	Cloud Logging + Cloud Monitoring + Cloud Trace

Costos estimados — escenario AMS multi-planta (3 plantas)

Asumiendo:

- 1 backend (1 vCPU 2GB) + 1 frontend (0.5 vCPU 0.5GB) por planta = 3 backends + 3 frontends
- Postgres compartido (4 vCPU 16GB)
- Object storage 200GB con 50GB egress/mes
- 50K req/día agregado

Capa		
Compute (3 backends + 3 frontends)	~\$220/mes	~\$170/mes
Postgres (4 vCPU 16GB)	~\$280/mes	~\$310/mes
Object storage 200GB + egress	~\$8/mes	~\$8/mes
Networking	~\$30/mes	~\$30/mes
Observability	incluido	~\$20/mes
Total estimado	~\$540/mes	~\$540/mes

Recomendación

Empate técnico, con ligera ventaja para GCP por:

1. **Cloud Run** tiene el mejor scale-to-zero del mercado para nuestro patrón "API por planta con uso variable" — paga solo lo usado.
2. **Cold start menor** (~1s vs 3-5s en Azure) — relevante para móvil del técnico capturando fallas.
3. **Vertex AI** + Gemini Flash es mejor relación precio/latencia que Azure OpenAI para tasks ligeras (clasificación, dedup) — Claude API se mantiene para razonamiento complejo.
4. **Artifact Registry + Cloud Build** mejor integrado con GitHub que Azure DevOps si seguimos con GitHub.

Ventaja de Azure: si Gold Fields ya usa Office 365 / Microsoft 365 corporativo, Azure AD SSO sale "gratis". GCP requiere Workspace Identity Federation (más config).

Plan de migración propuesto (si se aprueba)

Fase 1 (1 semana): Postgres managed + migración de SQLite con script (`api/database/connection.py` ya soporta `DATABASE_URL` postgres).

Fase 2 (2 semanas): containerizar para Cloud Run / Container Apps. La imagen actual (`asset-management-software-ocp-backend:latest`) ya es OCI estándar. Setup CI: GitHub Actions push → Artifact Registry → Cloud Run rollout.

Fase 3 (1 semana): Object storage para `data/` (fotos + DMS) — refactor `documents` JSON para guardar URLs firmadas en vez de base64.

Fase 4 (1 semana): WS sticky sessions (Cloud Run requiere session affinity habilitada o sustitución por SSE).

Fase 5: observability + alertas + cutover producción.

Total: ~5 semanas para migración full + 1 semana de pre-producción paralela.

Riesgos

- **Costo runaway si tráfico real > estimado:** ambas nubes facturan por uso. Configurar budget alerts mandatorio.
- **WS conn churn en Cloud Run scale-down:** requiere session affinity o reconnect aggressive (ya implementado en `wsSingleton.js`).
- **LanceDB:** ninguna nube tiene managed equivalent. Opciones: a) Vertex AI Vector Search (GCP); b) Cosmos DB con vector search (Azure); c) self-host LanceDB en VM dedicada.
- **Datos sensibles del cliente** (Gold Fields confidencialidad): verificar región y compliance ISO 27001. Ambas nubes lo cumplen pero requiere paperwork.

Siguiente paso recomendado

Si la decisión apunta a migrar:

1. Cotización formal Azure y GCP con TAM (Technical Account Manager) para descuentos por volumen anual.
2. POC de 2 semanas: levantar 1 entorno staging en GCP (Cloud Run + Cloud SQL) y comparar costo + latencia real con la VPS Hetzner actual.
3. Decisión final post-POC con datos reales.

Si la prioridad es estabilidad inmediata sin scope nuevo de migración, mantener Hetzner VPS con upgrade a 16GB RAM + segundo VPS para staging es la opción más eficiente (~\$50/mes total, sin cambio operacional).