

# SPIKE-1: Evaluación de despliegue Azure vs Google Cloud (SF-629)

**Fecha:** 2026-05-05 **Stack actual:** Hetzner VPS (Ubuntu 24.04) · 96GB SSD · 8GB RAM · Docker Compose · SQLite + LanceDB **Costo actual aprox:** ~25 EUR/mes

## Contexto

AMS-Production corre hoy en una VPS de Hetzner con 12 proyectos coexistiendo. Para escalar a múltiples plantas (Gold Fields, OCP-Maroc, FluorAlpha) sin riesgo cruzado y con SLA de cliente minero, se evalúa migrar a una nube hyperscaler.

## Comparativo

### Compute (backend FastAPI + frontend Vite/Nginx)

| Atributo                             |                              |                               |
|--------------------------------------|------------------------------|-------------------------------|
| Equivalente                          | App Service / Container Apps | Cloud Run                     |
| Modelo facturación                   | vCPU-seg + memoria           | vCPU-seg + memoria + requests |
| Cold start (containerized)           | 2-5s                         | 0.5-2s                        |
| Auto-scale a 0                       | Sí (Container Apps)          | Sí (Cloud Run)                |
| Costo 1 vCPU + 2GB always-on (24×30) | ~\$60/mes                    | ~\$50/mes                     |
| Concurrent requests por instancia    | 10-100 (configurable)        | 80-1000 (configurable)        |

### Persistencia (BD)

| Atributo              |                                       |                                                 |
|-----------------------|---------------------------------------|-------------------------------------------------|
| Postgres managed      | Azure Database for PostgreSQL         | Cloud SQL Postgres                              |
| Tier mínimo razonable | Burstable B1ms (1 vCPU 2GB) ~\$12/mes | db-f1-micro (0.6GB) ~\$10/mes pero suben rápido |
| Backups automáticos   | Sí, 7 días incluido                   | Sí, 7 días incluido                             |
| Networking            | VNet integration                      | VPC peering / Private IP                        |

Storage (fotos, DMS PDFs, audio capturas)

| Atributo       |                         |                          |
|----------------|-------------------------|--------------------------|
| Object storage | Blob Storage (Hot tier) | Cloud Storage (Standard) |
| Costo /GB/mes  | ~\$0.018                | ~\$0.020                 |
| Egress 1TB     | ~\$87                   | ~\$85                    |
| URLs firmadas  | SAS tokens              | Signed URLs              |

IA / LLM

| Atributo                       |                                                  |                                                     |
|--------------------------------|--------------------------------------------------|-----------------------------------------------------|
| Hosted Claude                  | ✗ (Anthropic API directo)                        | ✗ (Anthropic API directo)                           |
| Vertex AI / Azure OpenAI       | Sí (GPT-4o, Claude via marketplace)              | Sí (Gemini 1.5 Pro/Flash)                           |
| Vector DB managed              | Cosmos DB con vector search                      | Vertex AI Vector Search / AlloyDB                   |
| LanceDB hosted?                | No nativo, autohostear en VM                     | No nativo, autohostear en VM                        |
| Latencia desde Chile/Marruecos | Mejor con regiones Brazil South / France Central | Mejor con regiones South America East / Europe West |

Networking & Multi-región

| Atributo               |                                 |                                                  |
|------------------------|---------------------------------|--------------------------------------------------|
| Regiones LATAM         | Brazil South (São Paulo)        | South America East (São Paulo), Santiago (~2026) |
| Regiones EU            | Multiple, France Central activo | Europe West (Bélgica/Holanda)                    |
| CDN                    | Front Door / Azure CDN          | Cloud CDN                                        |
| Certificate management | Auto-renew con App Service      | Auto-renew con managed certs                     |

DevOps / CI

| Atributo           |                                                |                                                |
|--------------------|------------------------------------------------|------------------------------------------------|
| Container Registry | ACR                                            | Artifact Registry                              |
| CI/CD nativo       | Azure DevOps / GitHub Actions integration      | Cloud Build + GitHub trigger                   |
| Secrets            | Key Vault                                      | Secret Manager                                 |
| Observability      | Application Insights (incluido en App Service) | Cloud Logging + Cloud Monitoring + Cloud Trace |

Costos estimados — escenario AMS multi-planta (3 plantas)

Asumiendo: - 1 backend (1 vCPU 2GB) + 1 frontend (0.5 vCPU 0.5GB) por planta = 3 backends + 3 frontends  
- Postgres compartido (4 vCPU 16GB) - Object storage 200GB con 50GB egress/mes - 50K req/día agregado

| Capa                               |            |            |
|------------------------------------|------------|------------|
| Compute (3 backends + 3 frontends) | ~\$220/mes | ~\$170/mes |
| Postgres (4 vCPU 16GB)             | ~\$280/mes | ~\$310/mes |
| Object storage 200GB + egress      | ~\$8/mes   | ~\$8/mes   |
| Networking                         | ~\$30/mes  | ~\$30/mes  |
| Observability                      | incluido   | ~\$20/mes  |
| Total estimado                     | ~\$540/mes | ~\$540/mes |

Recomendación

Empate técnico, con ligera ventaja para GCP por:

- 1. **Cloud Run** tiene el mejor scale-to-zero del mercado para nuestro patrón "API por planta con uso variable" — paga solo lo usado.
- 2. **Cold start menor** (~1s vs 3-5s en Azure) — relevante para móvil del técnico capturando fallas.
- 3. **Vertex AI** + Gemini Flash es mejor relación precio/latencia que Azure OpenAI para tasks ligeras (clasificación, dedup) — Claude API se mantiene para razonamiento complejo.
- 4. **Artifact Registry + Cloud Build** mejor integrado con GitHub que Azure DevOps si seguimos con GitHub.

**Ventaja de Azure:** si Gold Fields ya usa Office 365 / Microsoft 365 corporativo, Azure AD SSO sale "gratis". GCP requiere Workspace Identity Federation (más config).

## Plan de migración propuesto (si se aprueba)

**Fase 1 (1 semana):** Postgres managed + migración de SQLite con script ( `api/database/connection.py` ya soporta `DATABASE_URL` postgres).

**Fase 2 (2 semanas):** containerizar para Cloud Run / Container Apps. La imagen actual ( `asset-management-software-ocp-backend:latest` ) ya es OCI estándar. Setup CI: GitHub Actions push → Artifact Registry → Cloud Run rollout.

**Fase 3 (1 semana):** Object storage para `data/` (fotos + DMS) — refactor `documents` JSON para guardar URLs firmadas en vez de base64.

**Fase 4 (1 semana):** WS sticky sessions (Cloud Run requiere session affinity habilitada o sustitución por SSE).

**Fase 5:** observability + alertas + cutover producción.

**Total:** ~5 semanas para migración full + 1 semana de pre-producción paralela.

## Riesgos

- **Costo runaway si tráfico real > estimado:** ambas nubes facturan por uso. Configurar budget alerts mandatorio.
- **WS conn churn en Cloud Run scale-down:** requiere session affinity o reconnect aggressive (ya implementado en `wsSingleton.js` ).
- **LanceDB:** ninguna nube tiene managed equivalent. Opciones: a) Vertex AI Vector Search (GCP); b) Cosmos DB con vector search (Azure); c) self-host LanceDB en VM dedicada.
- **Datos sensibles del cliente** (Gold Fields confidencialidad): verificar región y compliance ISO 27001. Ambas nubes lo cumplen pero requiere paperwork.

## Siguiente paso recomendado

Si la decisión apunta a migrar: 1. Cotización formal Azure y GCP con TAM (Technical Account Manager) para descuentos por volumen anual. 2. POC de 2 semanas: levantar 1 entorno staging en GCP (Cloud Run + Cloud SQL) y comparar costo + latencia real con la VPS Hetzner actual. 3. Decisión final post-POC con datos reales.

**Si la prioridad es estabilidad inmediata sin scope nuevo de migración,** mantener Hetzner VPS con upgrade a 16GB RAM + segundo VPS para staging es la opción más eficiente (~\$50/mes total, sin cambio operacional).